
XML parsing

Imprimé le 5 mai 2003

Projet	File parsing
Fichier	xmltools.m
Version	2.4
Date	mar2003
Auteur	Charles-Albert Lehalle
Mail	charles.lehalle@miriadtech.com
Relecteur	***NOT DEFINED***

Table des matières

1	XML TOOLS FOR MATLAB	3
1.1	READ AN XML FILE	5
1.1.1	Récupération du fichier dans un string.	5
1.1.2	Parsing.	5
1.2	SELECT A SUBSET OF z CHILD	6
1.3	WRITE AN XML STRUCTURE	6
1.3.1	Selection de la cible.	6
1.3.2	Ecriture proprement dite.	7
1.3.3	Fermeture.	7
2	Fonctions internes	7
2.1	parser un string xml	8
2.1.1	Si je n'ai plus de tag dans mon document.	8
2.1.2	je rencontre une fermeture.	9
2.1.3	je rencontre une ouverture.	9
2.1.4	Self closing tag.	10
2.1.5	Attributs.	10
2.1.6	If self-closing tag.	11
2.1.7	Appel du même code sur la suite.	11
2.1.8	Parse attribs.	12
2.2	Ecriture d'une structure xml	13
2.2.1	Ouverture du tag.	13
2.2.2	Ecriture des attributs.	13
2.2.3	Gestion des Auto closed tags.	14
2.2.4	Ecriture de la value.	14
2.2.5	Ecriture des enfants.	15
2.2.6	Fermeture du tag.	15
2.3	get childs with a specific tag name	15
2.3.1	udeblank.	16
2.3.2	emptystruct.	16
2.3.3	Tokens.	16

<xmltools.m>

1 XML TOOLS FOR MATLAB

This is an OCAMAWEB (<http://ocamaweb.sourceforge.net>) generated documentation.

This function manage the exchange of data between XML files and a MATLAB structure. The MATLAB structure is this : a **node** is a struct with fields *tag*, *value*, *attrs*, *child*. Where *tag* is the tag name, *value* its contents, *attrs* an array of structure with fields *name* and *value*, and *child* an array of such nodes.

All those fields are always present and can be empty except for the first node (root) that has only children.

The file `file.xml` containing :

```
<?xml version="1.0" ?>
<GUISCRIP>
<SEQUENCE><NAME VALUE="A@p&gt;B@a"/>
  <MODULE NAME="R6" KEY="A" ACTION="P">
  </MODULE>
  <MODULE NAME="Composante" KEY="B" ACTION="A">
    <PARAM NB="2" NAME="Method">VALUE</PARAM>
  </MODULE>
</SEQUENCE>
</GUISCRIP>
```

becomes this MATLAB structure :

```
child +-- tag: '?xml', attrs: name: 'VERSION', value: '1.0', value: '', child: []
+-- tag: 'GUISCRIP', attrs: name: '', value: '', value: '',
  child: +-- tag: 'SEQUENCE', attrs: name: '', value: '', value: '',
    child: +-- tag: 'NAME', attrs: name: 'VALUE', value: 'A@p&gt;B@a', value: '', child: []
      +-- tag: 'MODULE',
      !   attrs: +-- name: 'NAME', value: 'R6'
      !           +-- name: 'KEY', value: 'A'
      !           +-- name: 'ACTION', value: 'P',
      !           value: '', child: []
      +-- tag: 'MODULE',
      attrs: +-- name: 'NAME', value: 'Composante'
              +-- name: 'KEY', value: 'B'
              +-- name: 'ACTION', value: 'A',
      value: '',
      child: tag: 'PARAM',
              attrs: +-- name: 'NB', value: '2'
                      +-- name: 'NAME', value: 'Method'
              value: 'VALUE', child: []
```

using `z=xmltools('file.xml')` ;. And `xmltools(z)` ; produces :

```
<?xml VERSION="1.0"?>
<GUISCRIPT>
  <SEQUENCE>
    <NAME VALUE="A@p&gt;B@a"/>
    <MODULE NAME="R6" KEY="A" ACTION="P"/>
    <MODULE NAME="Composante" KEY="B" ACTION="A">
      <PARAM NB="2" NAME="Method">
        VALUE
      </PARAM>
    </MODULE>
  </SEQUENCE>
</GUISCRIPT>
```

And for instance, we have :

```
>> z.child(2).child(1).child(3).child.attrs(2)
ans =
    name: 'NAME'
    value: 'Method'
```

◇

```
function z ← xmltools( arg, out_file, varargin)
% XMLTOOLS - tools for managing xml data sets
%   - if arg is a string : arg is an XML file to convert into MATLAB struct
%   - if arg is a variable : it is a MATLAB struct to write into XML, to st-
%   dout if out_file is not given
% use :
%   z ← xmltools('filename.xml'); read an xml file and store it into z
%   xmltools(z,'filename.xml'); write z into the file
%   xmltools(z,'get','tag-name'); returns only subset of z child which name is tag-
%   name
%
% project 'File parsing'
% title   'XML parsing'
% author  'Charles-Albert Lehalle'
% mailto  'charles.lehalle@miriadtech.com'
% version '2.4'
% date    'mar2003'

version ← '2.4';
```

1.1 READ AN XML FILE

Utilise $\langle 1.1.1 \rangle$ $\langle 1.1.2 \rangle$ $\langle 1.2 \rangle$ $\langle 1.3 \rangle$

◇

```
if isstr(arg)

     $\langle$ R  cup  ration du fichier dans un string  $\rightarrow$  1.1.1 $\rangle$ 

     $\langle$ Parsing  $\rightarrow$  1.1.2 $\rangle$ 
    return
end

if  $\neg$ isstr(arg)

     $\langle$ SELECT A SUBSET OF z CHILD  $\rightarrow$  1.2 $\rangle$ 

     $\langle$ WRITE AN XML STRUCTURE  $\rightarrow$  1.3 $\rangle$ 
end
```

1.1.1 R  cup  ration du fichier dans un string.

Utilis   par $\langle 1.1 \rangle$

◇

```
fid  $\leftarrow$  fopen(arg, 'r');
F  $\leftarrow$  fread(fid);
s  $\leftarrow$  char(F');
fclose(fid);
```

1.1.2 Parsing.

Utilis   par $\langle 1.1 \rangle$

◇

```
z  $\leftarrow$  parse_xml(s);
```

1.2 SELECT A SUBSET OF *z* CHILD

Utilisé par <1.1>

◇

```
if length(varargin) == 1
% warning: I will have to change the value of next at some places
    next ← 'child';

    z ← arg;
    if ~isfield(z, next)
        error('XMLTOOLS:GET', 'For child selection, structured first argument is needed');
    end
    tag_name ← varargin{1};

    z ← get_childs(z, next, tag_name);
    return
end
```

1.3 WRITE AN XML STRUCTURE

Utilisé par <1.1> — Utilise <1.3.1> <1.3.2> <1.3.3>

◇

<Selection de la cible → 1.3.1>

<Ecriture proprement dite → 1.3.2>

<Fermeture → 1.3.3>

1.3.1 Selection de la cible.

Utilisé par <1.3>

◇

```
if nargin < 2
    fid ← 1;
else
    fid ← fopen(out_file, 'w');
end
```

1.3.2 Ecriture proprement dite.

Utilisé par $\langle 1.3 \rangle$

◇

```
write_xml(fid, arg);
```

1.3.3 Fermeture.

Utilisé par $\langle 1.3 \rangle$

◇

```
if nargin > 1
    fclose(fid);
end
```

2 Fonctions internes

Utilise $\langle 2.1 \rangle$ $\langle 2.1.8 \rangle$ $\langle 2.2 \rangle$ $\langle 2.3 \rangle$ $\langle 2.3.1 \rangle$ $\langle 2.3.2 \rangle$ $\langle 2.3.3 \rangle$

◇

$\langle \text{parser un string xml} \rightarrow 2.1 \rangle$

$\langle \text{Parse attribs} \rightarrow 2.1.8 \rangle$

$\langle \text{Ecriture d'une structure xml} \rightarrow 2.2 \rangle$

$\langle \text{get childs with a specific tag name} \rightarrow 2.3 \rangle$

$\langle \text{udeblank} \rightarrow 2.3.1 \rangle$

$\langle \text{emptystruct} \rightarrow 2.3.2 \rangle$

$\langle \text{Tokens} \rightarrow 2.3.3 \rangle$

2.1 parser un string xml

Utilisé par ⟨2⟩ — Utilise ⟨2.1.1⟩ ⟨2.1.2⟩ ⟨2.1.3⟩

◇

```
function [z, str] ← parse_xml( str, current_tag, current_value, attribs, idx)

next ← 'child';

if nargin < 2
    current_tag ← '';
    current_value ← '';
    attribs ← '';
    idx ← 0;
end
z ← [];

eot ← 0;

while ¬eot ∧ ¬isempty(udeblank(deblank(str)))

    f_end ← strfind(str, '</');
    f_beg ← strfind(str, '<');

    (Si je n'ai plus de tag dans mon document → 2.1.1)

    if isempty(f_end)
        f_end ← length(str)
    else
        f_end ← f_end(1);
    end
    if isempty(f_beg)
        f_beg ← length(str)
    else
        f_beg ← f_beg(1);
    end

    if f_end ≤ f_beg
        (je rencontre une fermeture → 2.1.2)
    else
        (je rencontre une ouverture → 2.1.3)
    end
end
```

2.1.1 Si je n'ai plus de tag dans mon document.

Utilisé par ⟨2.1⟩

◇


```

if isempty(f_end) & isempty(f_beg)

    if ~strcmp(lower(current_tag), '?xml') & ~isempty(current_tag)
        error('xmltools:parse_xml', 'malformed xml string (current [%s])', current_tag);
    else
        fprintf('end parsing at level %d\n', idx);
        eot ← 1;
        return
    end
end

```

2.1.2 je rencontre une fermeture.

Utilisé par <2.1>

◇

```

new_tag ← str((f_end+2):end);
str_t ← str(1:f_end-1);
f_end ← strfind(new_tag, '>');
if isempty(f_end)
    error('xmltools:parse_xml', 'malformed xml string : never ending tag [%s] encountered', current_tag);
end
f_end ← f_end(1);
str ← new_tag(f_end+1:end); % reste
new_tag ← new_tag(1:f_end-1);
if ~strcmp(new_tag, current_tag)
    error('xmltools:parse_xml', 'malformed xml string : [%s] not properly closed (closing [%s] encountered)', current_tag, new_tag);
end
fprintf('%sclose [%s]\n', repmat(' ', 2*(idx-1), 1), current_tag);
z.tag ← upper(current_tag);
z.attrs ← parse_attrs(attrs);
z.value ← udeblank(deblank(sprintf('%s %s', current_value, str_t)));
eot ← 1;

```

2.1.3 je rencontre une ouverture.

je vais appeler le même code sur ce qu'il y a après moi

Utilisé par <2.1> — Utilise <2.1.4> <2.1.5> <2.1.6> <2.1.7>

◇

```

current_value ← sprintf('%s %s', current_value, str(1:f_beg-1));
new_tag ← str(f_beg+1:end);
f_end ← strfind(new_tag, '>');
if isempty(f_end)
    error('xmltools:parse_xml', 'malformed xml string : never ending tag encountered');
end
f_end ← f_end(1);
str_t ← new_tag(f_end+1:end);
new_tag ← new_tag(1:f_end-1);
if (new_tag(end) ≡ '/') ∨ (new_tag(end) ≡ '?')
    ⟨Self closing tag → 2.1.4⟩
end
⟨Attributs → 2.1.5⟩
fprintf('%sopen [%s]\n', repmat(' ', 2*idx, 1), new_tag);

if eot
    ⟨If self-closing tag → 2.1.6⟩
else
    ⟨Appel du même code sur la suite → 2.1.7⟩
end
end

```

2.1.4 Self closing tag.

Je met (temporairement!) eot à 1, cela me permet de passer quelques lignes de code tranquillement

Utilisé par ⟨2.1.3⟩

◇

```
eot ← 1;
```

2.1.5 Attributs.

Utilisé par ⟨2.1.3⟩

◇

```

f_beg ← strfind(new_tag, ' ');
if isempty(f_beg)
    new_attribs ← '';
if eot

```

```

new_tag ← new_tag(1:end-1);
end
else
    new_attribs ← new_tag(f_beg+1:end);
    if eot
new_attribs ← new_attribs(1:end-1);
    end
    new_tag      ← new_tag(1:f_beg-1);
end

```

2.1.6 If self-closing tag.

Utilisé par (2.1.3)

◇

```

fprintf('%sclose [%s]\n', repmat(' ', 2*idx,1), new_tag);
new_attribs ← parse_attribs( new_attribs);
if isfield(z, next)
    nxt ← getfield(z, next);
    nxt(end+1) ← struct( 'tag', new_tag, 'attribs', new_attribs, 'value', '', next, []);
    z ← setfield(z, next, nxt);
% z.(next)(end+1) = struct( 'tag', new_tag, 'attribs', new_attribs, 'value', '', next, []);
else
    z ← setfield(z, next, struct( 'tag', new_tag, 'attribs', new_attribs, 'value', '', next,
% z.(next) = struct( 'tag', new_tag, 'attribs', new_attribs, 'value', '', next, []);
end
str ← str_t;
eot ← 0;

```

2.1.7 Appel du même code sur la suite.

Utilisé par (2.1.3)

◇

```

% et stockage du resultat dans mes children.
% Le code met aussi à jour le string courant str,
% il en enlève la partie correspondant au string que je viens de trouver.
[t,str] ← parse_xml(str_t, new_tag, '', new_attribs, 1+idx);
if isfield(t, next)
    nx ← getfield( t, next);
% nx = t.(next);
else

```

```

nx ← [];
end
if isfield(z, next)
    nxt ← getfield(z, next);
    nxt(end+1) ← struct( 'tag', t.tag, 'attrs', t.attrs, 'value', t.value, next, nx);
    z ← setfield(z, next, nxt);
% z.(next)(end+1) = struct( 'tag', t.tag, 'attrs', t.attrs, 'value', t.value, next, nx);
else
    z ← setfield(z, next, struct( 'tag', t.tag, 'attrs', t.attrs, 'value', t.value, next, nx));
% z.(next) = struct( 'tag', t.tag, 'attrs', t.attrs, 'value', t.value, next, nx);
end

```

2.1.8 Parse attrs.

Utilisé par <2>

◇

```

function z ← parse_attrs( a)
if isempty(a)
    z ← struct( 'name', '', 'value', '');
    return
end
b ← tokens(a, ' ');
j ← 1;
for i←1:length(b)
    if ~isempty(b{i})
        t ← tokens(b{i}, '←');
        if length(t) == 2
            u ← t{2};
            if u(1) == '"'
                u ← u(2:end);
            end
            if u(end) == '"'
                u ← u(1:end-1);
            end
            z(j) ← struct( 'name', upper(t{1}), 'value', u);
        else
            z(j) ← struct( 'name', upper(a), 'value', '');
        end
        j ← j +1;
    end
end
end

```

2.2 Ecriture d'une structure xml

Utilisé par <2> — Utilise <2.2.1> <2.2.4> <2.2.5> <2.2.6>

◇

```
function z ← write_xml(fid, xml_struct, idx)

next ← 'child';

if nargin < 3
    idx ← 0;
end

margin ← repmat(' ', 2*idx, 1);

closed_tag ← 1;
<Ouverture du tag → 2.2.1>

<Ecriture de la valeur → 2.2.4>

<Ecriture des enfants → 2.2.5>

<Fermeture du tag → 2.2.6>
```

2.2.1 Ouverture du tag.

Utilisé par <2.2> — Utilise <2.2.2> <2.2.3>

◇

```
if isfield(xml_struct, 'tag')
    closed_tag ← 0;
    fprintf(fid, '%s<%s', margin, xml_struct.tag);
    <Ecriture des attributs → 2.2.2>

    <Gestion des Auto closed tags → 2.2.3>
end
```

2.2.2 Ecriture des attributs.

Utilisé par <2.2.1>

◇

```
if ¬isfield(xml_struct, 'attribs')
```

```

        error('xmltools:write_xml', 'malformed MATLAB xml structure : tag without at-
tribs');
    end
    for i←1:length(xml_struct.attrs)
        if ~isempty(xml_struct.attrs(i).name)
            fprintf(fid, ' %s←"%s"', xml_struct.attrs(i).name, xml_struct.attrs(i).value);
        end
    end
end

```

2.2.3 Gestion des Auto closed tags.

Si le tag n'est pas auto fermé, alors `closed_tag` est à zéro

Utilisé par <2.2.1>

◇

```

if ~isfield(xml_struct, next)
    error('xmltools:write_xml', 'malformed MATLAB xml structure : tag without %s', next);
end
if ~isfield(xml_struct, 'value')
    error('xmltools:write_xml', 'malformed MATLAB xml structure : tag without va-
lue');
end
if xml_struct.tag(1) == '?'
    fprintf(fid, '?>\n');
    closed_tag ← 1;
elseif isempty(getfield(xml_struct, next)) & isempty(xml_struct.value)
% elseif isempty(xml_struct.(next)) & isempty(xml_struct.value)
    fprintf(fid, '/>\n');
    closed_tag ← 1;
else
    fprintf(fid, '>\n');
end
end

```

2.2.4 Ecriture de la value.

Utilisé par <2.2>

◇

```

if isfield(xml_struct, 'value')
    if ~isempty(xml_struct.value)
        fprintf(fid, '%s%s\n', margin, xml_struct.value);
    end
end
end

```

2.2.5 Ecriture des enfants.

Utilisé par ⟨2.2⟩

◇

```
if ~isfield(xml_struct, next)
    error('xmltools:write_xml', 'malformed MATLAB xml structure : tag without %s', next);
end
those_children ← getfield(xml_struct, next);
% those_children = xml_struct.(next);
for i←1:length(those_children)
    write_xml(fid, those_children(i), idx+1);
end
```

2.2.6 Fermeture du tag.

Utilisé par ⟨2.2⟩

◇

```
if ~closed_tag
    fprintf(fid, '%s</%s>\n', margin, xml_struct.tag);
end
```

2.3 get childs with a specific tag name

Utilisé par ⟨2⟩

◇

```
function z ← get_childs(z, next, tag_name);
u ← getfield(z, next);
zo ← [];
for i←1:length(u)
    v ← u(i);
    if strcmp(v.tag, tag_name)
        if isempty(zo)
            zo.anext← v;
        else
            zo.anext(end+1) ← v;
        end
    end
end
```

```

end
z ← [ zo.anext ];

```

2.3.1 udeblank.

Utilisé par ⟨2⟩

◇

```

function s ← udeblank(str)
s ← deblank(str(end:-1:1));
s ← s(end:-1:1);
if length(s) ≡ 0
    s ← '';
end

```

2.3.2 emptystruct.

Utilisé par ⟨2⟩

◇

```

function z ← emptystruct(next)
z ← struct( 'tag', [], 'value', [], 'attrs', [], next, []);

```

2.3.3 Tokens.

Utilisé par ⟨2⟩

◇

```

function l ← tokens(str,del)
l←{} ;
% Boucle sur les tokens.
del ← sprintf(del) ;
while ¬isempty(str)
    [tok,str] ← strtok(str,del) ;
    l{end+1} ← tok ;
end

```
